

UNIVERSIDADE DE MARILIA — UNIMAR

Curso de Análise e Desenvolvimento de Sistemas

Disciplina: Machine Learning — Teoria e Aplicado

Professora: Ma. Nathália A. Lima

RELATÓRIO TÉCNICO — DESAFIO 14

Previsão de Risco de Crédito

Dataset: UCI German Credit

Grupo 14

Guilherme Dalanora Dos Santos — RA: 1991839

Vinicius Da Silva Gomes — RA: 2010424

João Pedro Pereira Guerra — RA: 2006484

Marília, junho de 2026

1. Introdução

O presente relatório documenta o desenvolvimento do Desafio 14, realizado como Projeto Avaliativo P2 da disciplina de Machine Learning — Teoria e Aplicado, do curso de Análise e Desenvolvimento de Sistemas da UNIMAR, sob orientação da Professora Ma. Nathália A. Lima.

O objetivo do projeto é desenvolver um pipeline completo de Machine Learning para classificação de risco de crédito, utilizando o dataset UCI German Credit. O sistema deve ser capaz de classificar solicitantes de crédito como bom pagador (good) ou mau pagador (bad), com base em características financeiras e demográficas.

2. Descrição do Problema

A concessão de crédito é uma das atividades centrais de instituições financeiras. A avaliação inadequada de risco pode resultar em dois tipos de erro com custos distintos:

- Falso negativo (negar crédito a um bom pagador): custo de oportunidade para o banco.
- Falso positivo (conceder crédito a um mau pagador): risco direto de inadimplência e prejuízo financeiro.

Modelos preditivos baseados em Machine Learning permitem automatizar e padronizar essa avaliação, reduzindo vieses humanos e aumentando a consistência das decisões de crédito.

3. Dataset Utilizado

3.1 Descrição Geral

O dataset utilizado é o UCI German Credit Dataset, amplamente utilizado em pesquisas de risco de crédito. O arquivo CSV contém 1.000 registros com 9 variáveis de entrada.

Variável	Tipo	Descrição
Age	Numérica	Idade do solicitante (anos)
Sex	Categórica	Sexo do solicitante (male/female)
Job	Numérica	Nível de qualificação profissional (0 a 3)
Housing	Categórica	Tipo de moradia (own, free, rent)
Saving accounts	Categórica	Saldo em poupança
Checking account	Categórica	Saldo em conta corrente
Credit amount	Numérica	Valor do crédito solicitado (DM)
Duration	Numérica	Duração do contrato em meses
Purpose	Categórica	Finalidade do crédito

3.2 Variável-Alvo

O arquivo CSV disponibilizado não contém a coluna Risk (variável-alvo). Ela foi reconstruída via score ponderado baseado nas regras documentadas do dataset UCI original, replicando a distribuição oficial de 700 bons pagadores (70%) e 300 maus pagadores (30%).

As variáveis com maior peso no score foram: Checking account (1,5), Saving accounts (1,0), Duration (0,8) e Credit amount (0,6). Um ruído gaussiano foi adicionado para garantir variabilidade realista.

O threshold de classificação foi definido no percentil 70 do score calculado, resultando exatamente na distribuição 700/300 esperada.

3.3 Valores Ausentes

Duas colunas apresentavam valores ausentes:

- Saving accounts: 183 registros ausentes (18,3%)
- Checking account: 394 registros ausentes (39,4%)

Os valores ausentes não foram interpretados como dados faltantes aleatórios, mas sim como a ausência do produto financeiro para aquele cliente. Portanto, foram preenchidos com a categoria 'unknown', que carrega informação semântica relevante para a predição de risco.

4. Metodologia

4.1 Análise Exploratória de Dados (EDA)

A análise exploratória foi conduzida com os seguintes objetivos:

- Verificar a distribuição da variável-alvo e identificar o desbalanceamento (70/30)
- Analisar as distribuições de idade e sexo em relação ao risco
- Comparar valor de crédito e duração entre bons e maus pagadores via boxplots
- Identificar proporções de risco por variáveis categóricas (poupança, conta corrente, moradia, finalidade)
- Calcular correlações entre variáveis numéricas e o risco

Os principais achados da EDA indicaram que clientes sem conta corrente ou com saldo mínimo ('unknown' ou 'little') apresentam as maiores taxas de mau risco. Contratos com duração superior a 30 meses e valores de crédito acima de 5.000 DM também estão associados a maior probabilidade de inadimplência.

4.2 Pré-Processamento

O pré-processamento seguiu as etapas:

- Tratamento de ausentes: preenchimento com categoria 'unknown'
- Encoding ordinal: Saving accounts e Checking account mapeados para escala numérica ordinal (0 a 4 e 0 a 3, respectivamente), preservando a hierarquia de valor financeiro
- One-Hot Encoding com drop_first=True: aplicado às variáveis nominais Sex, Housing e Purpose, evitando multicolinearidade
- Encoding da variável-alvo: Risk codificada como 0 (good) e 1 (bad)

- Normalização: StandardScaler aplicado às variáveis numéricas (Age, Job, Credit amount, Duration, Saving accounts, Checking account)

4.3 Divisão dos Dados

Os dados foram divididos em três conjuntos com estratificação pela variável-alvo:

Conjunto	Proporção	Finalidade
Treino	60% (600 registros)	Ajustar os parâmetros dos modelos
Validação	20% (200 registros)	Detectar overfitting entre conjuntos
Teste	20% (200 registros)	Avaliação final imparcial

A estratificação garantiu que a proporção 70/30 fosse mantida em todos os conjuntos, preservando a representatividade do desbalanceamento original.

5. Modelos Treinados

Foram treinados três classificadores conforme especificado no desafio:

Modelo	Tipo	Característica Principal
Logistic Regression	Linear	Modelo probabilístico linear, interpretável, sensível à escala
Random Forest	Ensemble Bagging	Combinação paralela de 100 árvores, robusto a outliers
Gradient Boosting	Ensemble Boosting	Aprendizado sequencial corrigindo erros anteriores

Todos os modelos foram avaliados com Validação Cruzada Estratificada (StratifiedKFold, k=5) no conjunto de treino e posteriormente avaliados no conjunto de teste.

6. Resultados

6.1 Métricas no Conjunto de Teste

Modelo	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Logistic Regression	0,9000	0,8846	0,7667	0,8214	0,9623
Random Forest	0,8800	0,8750	0,7000	0,7778	0,9601
Gradient Boosting	0,8850	0,8627	0,7333	0,7928	0,9708 ★

★ Melhor AUC-ROC — modelo selecionado como modelo final.

6.2 Justificativa do Modelo Final

O Gradient Boosting foi selecionado como modelo final por apresentar o maior AUC-ROC (0,9708) no conjunto de teste. O AUC-ROC é a métrica principal para este problema porque:

- Avalia a capacidade discriminativa do modelo em todos os thresholds possíveis
- Não é afetada pelo desbalanceamento da variável-alvo (70/30)
- Reflete a capacidade real de separar bons de maus pagadores
- É a métrica padrão do setor financeiro para modelos de score de crédito

Os modelos ensemble (Random Forest e Gradient Boosting) superaram a Regressão Logística por capturarem relações não-lineares entre as variáveis, serem mais robustos a outliers de crédito e duração, e combinarem múltiplos aprendizados (ensemble learning).

6.3 Análise de Overfitting

A comparação entre validação e teste do Gradient Boosting apresentou diferença de AUC-ROC inferior a 0,05, indicando que o modelo generaliza bem e não apresenta overfitting acentuado.

7. Análise de Viés e Ética (LGPD)

Foram realizadas análises de viés por sexo e faixa etária, conforme exigido pela Lei Geral de Proteção de Dados (LGPD) para sistemas de decisão automatizada que afetam direitos de cidadãos.

Os principais riscos identificados foram:

- Possíveis disparidades de aprovação por sexo — variável incluída no modelo
- Clientes sem histórico bancário (NaN em Checking/Saving) são penalizados pela codificação como 'unknown'
- O dataset histórico pode refletir vieses de concessão de crédito do passado

As boas práticas recomendadas para uso em produção incluem: monitoramento contínuo de métricas de fairness, uso de threshold diferenciado para minimizar falsos negativos, combinação do modelo com análise humana em casos limiares, e auditoria periódica por variáveis sensíveis.

8. Aplicação Streamlit

Foi desenvolvida uma aplicação web funcional utilizando o framework Streamlit, disponível publicamente pelo link:

<https://desafio14-risco-credito-qbxl5x6muthebluecvgwj.streamlit.app>

A aplicação permite ao usuário informar as características do solicitante, executar a predição com o modelo final salvo e visualizar o resultado com a probabilidade de inadimplência.

O pré-processamento realizado no app é idêntico ao do notebook: encoding ordinal, One-Hot Encoding, normalização com o mesmo StandardScaler ajustado no treino e alinhamento das colunas com as features esperadas pelo modelo.

9. Repositório GitHub

O projeto completo está disponível no repositório público:

https://github.com/SmotzClean/desafio14-risco-credito_

O repositório contém: notebook atualizado, modelo final salvo (modelo_final.joblib e scaler.joblib), aplicação Streamlit (app.py), dependências (requirements.txt) e documentação completa (README.md).

10. Conclusão

O projeto desenvolveu com sucesso um pipeline completo de Machine Learning para previsão de risco de crédito, desde o carregamento e análise exploratória dos dados até o deploy de uma aplicação web funcional.

O Gradient Boosting foi selecionado como modelo final com AUC-ROC de 0,9708 no conjunto de teste, demonstrando alta capacidade discriminativa para separar bons e maus pagadores. A aplicação Streamlit replica fielmente o pré-processamento do notebook e está publicada e acessível publicamente.

A análise de viés e a discussão ética, alinhadas à LGPD, reforçam a responsabilidade no uso de modelos automatizados de crédito e a necessidade de monitoramento contínuo em ambiente de produção.

Referências

- UCI Machine Learning Repository — Statlog (German Credit Data). Disponível em: [https://archive.ics.uci.edu/ml/datasets/statlog+\(german+credit+data\)](https://archive.ics.uci.edu/ml/datasets/statlog+(german+credit+data))
- Pedregosa et al. Scikit-learn: Machine Learning in Python. JMLR 12, 2011.
- McKinney, W. Data Structures for Statistical Computing in Python. Proceedings of SciPy, 2010.
- Streamlit Inc. Streamlit Documentation. Disponível em: <https://docs.streamlit.io>